

Pembersihan Korpus PDF Putusan PN Surabaya

Tujuan: mengubah 273 PDF di PDF_Putusan/ menjadi teks bersih di CLEAN_TXT/ plus satu file CSV ringkas (_MANIFEST.csv) yang berisi nomor perkara dan nama hakim.

Cara pakai: jalankan cell berurutan dari atas ke bawah (Kernel > Restart & Run All). Ubah DRY_RUN = True di cell **Konfigurasi** (cell kode pertama) kalau hanya ingin melihat rencana tanpa memindah file.

Prasyarat: poppler-utils terinstal (pdftohtml , pdfinfo). Hanya memakai library standar Python (re , shutil , hashlib , csv , subprocess).

Struktur notebook: konfigurasi & pola regex di bagian atas, lalu beberapa fungsi utama per tahap, lalu satu cell untuk menjalankan tiap tahap.

```
In [1]: # ===== KONFIGURASI & IMPORT (satu-satunya bagian yang perlu
import csv
import hashlib
import html
import re
import shutil
import subprocess
from collections import Counter
from pathlib import Path

# ----- Konfigurasi (satu-satunya bagian yang perlu diubah) -----

FOLDER_SUMBER = Path("PDF_Putusan")
FOLDER_BERSIH = Path("CLEAN_TXT")
FOLDER_SISIH = Path("_EXCLUDE")
FILE_MANIFEST = Path("_MANIFEST.csv")
DRY_RUN = False # True = hanya mencetak rencana, tidak memindah/menul
BATAS_FILE = 0 # 0 = proses semua file; isi angka kecil (mis. 5) unt

# ----- Konstanta filter font (hasil audit: berlaku di 273/273 file)
UKURAN_WATERMARK = 40 # watermark "Mahkamah Agung Republik Indone
WARNA_HEADER = "#3b3b3b" # header "Direktori Putusan" + URL selalu
UKURAN_DISCLAIMER = 8 # blok Disclaimer selalu 8pt
TOLERANSI_BARIS = 4 # dua kotak teks dianggap sebaris bila beda
BATAS_TANPA_TEKS = 2000 # file 1 halaman dengan teks < ini dianggap
BATAS_ABORT = 20 # pengaman: batalkan pemindahan bila file b

KOLOM_MANIFEST = ["file_pdf", "nama_asli", "status", "alasan", "nomor_he
    "nomor_footer", "nomor_cocok", "tahun", "jenis", "pengadilan",
    "hakim_ketua", "hakim_anggota", "hakim_tunggal", "cara_hakim",
    "halaman_pdf", "jumlah_baris", "jumlah_karakter"]

# ----- Konfigurasi tahap 2: ekstraksi entitas -----
INPUT_TXT = Path("CLEAN_TXT")
OUTPUT_CLEAN = Path("OUTPUT_CLEAN")
KOLOM_ENTITAS = ["nomor_putusan", "nama_terdakwa_1", "nama_terdakwa_2", "nam
```

```

KOLOM_TAMBAH = ["file_txt", "jenis_dokumen", "entitas_berlaku", "total_entit
KOLOM_CSV = KOLOM_ENTITAS + KOLOM_TAMBAH
TANDA_KOSONG = "-"
BATAS_PREVIEW = 5
CONTOH_DEMO = "T-1016_Pid.B_2026_PN Sby.txt"
LABEL_CETAK = {"nomor_putusan": "Nomor Putusan", "nama_terdakwa_1": "Nama Te
JEJAK_ATURAN = {"nomor_putusan": "baris judul 'Nomor : ' + POLA_NOMOR", "nam

# Alasan standar bila sebuah entitas kosong (dipakai ekstrak())
PESAN_KOSONG = {
    "nomor_putusan": "nomor tidak terbaca pada judul dokumen",
    "nama_terdakwa_1": "label Nama lengkap/terdakwa tidak ditemukan di bl
    "nama_terdakwa_2": "dokumen ini tidak mempunyai terdakwa kedua/ketiga
    "nama_terdakwa_3": "dokumen ini tidak mempunyai terdakwa kedua/ketiga
    "tuntutan_pidana": "amar Tuntutan nomor 1 tidak memuat perbuatan yang
    "tuntutan_kuhp": "amar Tuntutan nomor 1 tidak memuat Pasal KUHP",
    "tuntutan_hukuman": "amar Tuntutan nomor 2 tidak memuat durasi sesudah
    "putusan_pidana": "amar MENGADILI nomor 1 tidak memuat perbuatan yang
    "putusan_hukuman": "amar MENGADILI nomor 2 tidak memuat durasi sesudah
    "tanggal_putusan": "tanggal 'pada hari ..., tanggal ...' tidak ditemu
    "hakim_ketua": "nama sebelum 'Hakim Ketua' tidak ditemukan di penutup
    "hakim_anggota_1": "daftar 'masing-masing sebagai Hakim Anggota' tida
    "hakim_anggota_2": "anggota kedua tidak ditemukan (misalnya hakim tun
    "panitera": "pola 'dibantu oleh ... Panitera Pengganti' tidak ditemuk
    "penuntut_umum": "nama sebelum 'Penuntut Umum' tidak ditemukan di pen
}

```

```

In [2]: # ===== TAHAP 1 - POLA REGEX & KAMUS =====
# Keputusan penyaringan berdasar UKURAN dan WARNA font, bukan menebak isi

# Kamus perbaikan kata berhuruf renggang ("P U T U S A N" -> "PUTUSAN").
# Hanya berisi kata yang sudah diverifikasi muncul di korpus ini.
KATA_RENGGANG = {
    "P U T U S A N": "PUTUSAN", "P E N E T A P A N": "PENETAPAN",
    "M E N G A D I L I": "MENGADILI", "M E N E T A P K A N": "MENETAPKAN"
    "M E N U N T U T": "MENUNTUT", "M E L A W A N": "MELAWAN",
    "S U B S I D A I R": "SUBSIDAIR", "K E D U A": "KEDUA",
    "A T A U": "ATAU", "A t a u": "Atau", "M A K A": "MAKA",
    "M a k a": "Maka", "B a h w a": "Bahwa", "N a m a": "Nama",
    "P e k e r j a a n": "Pekerjaan", "A g a m a": "Agama",
    "L a w a n": "Lawan", "L A W A N": "LAWAN", "l a w a n": "lawan",
    "M e l a w a n": "Melawan", "U m u r": "Umur",
    "J u m l a h": "Jumlah", "m e m b a c a": "membaca",
    "m e n d e n g a r": "mendengar", "M e i": "Mei", "J u l i": "Juli",
    "N I H I L": "NIHIL", "A T K": "ATK", "S T M": "STM", "S M K": "SMK",
    "L A W F I R M": "LAW FIRM", "R O C H M A": "ROCHMA",
    "Y U N A W A T": "YUNAWAT", "G U M I N A": "GUMINA",
}

POLA_BARIS_SAMPAH = re.compile(r"^[^\u2013\u2014:\.\s]+$")

# --- pola nama hakim ---
GELAR = (r"(?:S\.?H\.?|SH\.?|M\.?H\.?|M\.?Hum\.?|Dr\.?|Dra\.?|Drs\.?|
    r"|H\.?J\.?|CPArb\.?|S\.?E\.?|SE\.?|MM\.?|H\.?S\.?|M\.?K\.?)")
POLA_NAMA = re.compile(rf"[A-Z][\w\.-]*(?:\s+[A-Z][\w\.-]*)*[,\.]\s*{GE
POLA_KELEBIH = re.compile(r"(?i)diputuskan dalam|ditetapkan dalam|
    r"rapat permusyawaratan|oleh\s+kami")
POLA_ANCHOR = re.compile(r"(?i)panitera\s+pengganti\s*[,\.]\s*hakim"
    r"|hakim\s+tunggal"
    r"|hakim\s*(?:-\s*hakim\s*)?(?:ketua|anggota)")

```

```

POLA_SISA = re.compile(r"(?i)^(halaman|hal)\b|\bdari\s+\d+\s+(hal|halaman
                        r"|^(t\s*\.\?\s*t\s*\.\?\s*d)")
POLA_TTD = re.compile(r"^(t\s*\.\?\s*t\s*\.\?\s*d\s*\.\?\s*)+$", re.I)
POLA_TUNGGAHAL_KALIMAT = re.compile(
    r"(?i)(.{0,80}?)\s*,?\s*(?:selaku\s+)?(?:hakim\s+pengadilan\s+negeri"
    r"|hakim\s+ketua\s+majelis)")

# --- pola nomor perkara & nama file ---
POLA_NOMOR = re.compile(r"(\d+)\s*/?\s*([A-Za-z][\w.-]*)(?:[ /][A-Za-z][\w.-]*)"
POLA_NAMA_FILE = re.compile(r"^(\\d+)_([\\w.-]+?)_(\\d{4})_PN", re.I)

# --- validasi ---
TRIGGER = {
    "nama (lengkap|terdakwa)": r"nama (lengkap|terdakwa) :",
    "menyatakan terdakwa": r"menyatakan terdakwa",
    "menjatuhkan pidana": r"menjatuhkan pidana",
    "diputuskan dalam": r"diputuskan dalam",
    "hakim ketua": r"hakim ketua",
}

NOISE = [r"^Mahkamah Agung Republik Indonesia$", r"mahkamahagung.go.id",
          r"^Disclaimer$", r"^Direktori Putusan Mahkamah Agung Republik In

```

Tahap 1 — Fungsi utama pembersihan PDF

```

In [3]: # ===== TAHAP 1 - FUNGSI UTAMA: baca & bersihkan satu PDF =====
# Dua fungsi utama:
# proses_satu_pdf(path_pdf) -> (daftar_baris_bersih, hakim)
# ekstrak_hakim(daftar_baris) -> {"ketua", "anggota", "tunggal", "cara"}

def proses_satu_pdf(path_pdf):
    """Pipeline lengkap satu file:
    baca PDF -> saring watermark/header/disclaimer -> gabung jadi baris
    -> rapikan teks -> ambil nama hakim."""

    # --- 1. Baca PDF jadi kotak-kotak teks (poppler; -i = jangan tulis g
    xmlek = subprocess.run(
        ["pdftohtml", "-xml", "-stdout", "-hidden", "-i", str(path_pdf)],
        capture_output=True, text=True,
    ).stdout

    # {id_font: (ukuran, keluarga, warna)}
    fontspec = {}
    pola_font = r"<fontspec id=\"(\d+)\" size=\"([\\d.]+)\" family=\"([\\^]+)\" c
    for cocok in re.finditer(pola_font, xmlek):
        fontspec[cocok.group(1)] = (float(cocok.group(2)), cocok.group(3))

    # daftar kotak: {halaman, atas, kiri, id_font, teks}
    kotak = []
    for nomor, halaman in enumerate(re.findall(r"<page.*?</page>", xmlek),
        for cocok in re.finditer(r"<text ([\\^>]*)>(.*?)</text>", halaman,
            atribut = dict(re.findall(r'([\\w+)=\"([\\^]*)\"', cocok.group(1))
            teks = html.unescape(re.sub(r"<[\\^>]+>", "", cocok.group(2)))
            teks = re.sub(r"\\s{2,}", " ", teks).strip()
            if teks:
                kotak.append({"halaman": nomor, "atas": int(atribut["top"]
                    "kiri": int(atribut["left"])),

```

```

        "id_font": atribut.get("font"), "teks": tek

# --- 2. Buang watermark / header situs / disclaimer (berdasar UKURAN
tersaring = []
for k in kotak:
    ukuran, _, warna = fontspec.get(k["id_font"], (0, "", ""))
    if ukuran >= UKURAN_WATERMARK:
        continue
    if warna == WARNA_HEADER:
        continue
    if ukuran == UKURAN_DISCLAIMER:
        continue
    tersaring.append(k)

# --- 3. Susun kotak menjadi baris (kotak yang tingginya mirip digabu
urut = sorted(tersaring, key=lambda k: (k["halaman"], k["atas"], k["k
gabungan, tampil = [], None
for k in urut:
    kunci = (k["halaman"], round(k["atas"] / TOLERANSI_BARIS))
    if tampil and kunci == tampil["kunci"]:
        tampil["teks"] += " " + k["teks"]
    else:
        tampil = {"kunci": kunci, "teks": k["teks"]}
        gabungan.append(tampil)
baris_mentah = [b["teks"] for b in gabungan]

# --- 4. Rapikan: spasi, 'H a k i m', huruf renggang, baris tanda bac
rapi = []
for baris in baris_mentah:
    baris = re.sub(r"\s{2,}", " ", baris).strip()
    baris = re.sub(r"H\s+a\s+k\s+i\s+m", "Hakim", baris, flags=re.I)
    for renggang, rapat in KATA_RENGGANG.items():
        baris = baris.replace(renggang, rapat)
    if baris and not POLA_BARIS_SAMPAH.match(baris):
        rapi.append(baris)

# --- 5. Sambung baris berakhiran '-' dengan baris berikut (tanda hub
#      dipertahankan: 'Laki-laki', 'masing-masing', 'perundang-unda
tersambung = []
for baris in rapi:
    if tersambung and tersambung[-1].endswith("-") and baris[:1].islo
        tersambung[-1] = tersambung[-1] + baris
    else:
        tersambung.append(baris)

# --- 6. Seragamkan label nomor: 'No.', 'NOMOR :', 'Perkara Nomor :'
baris_akhir = []
for baris in tersambung:
    baris = re.sub(r"(?i)^(?:perkara\s+)?n(?:omor|o)\.?\s*:", "Nomor
    baris_akhir.append(re.sub(r"^Nomor :(\S)", r"Nomor : \1", baris))

return baris_akhir, ekstrak_hakim(baris_akhir)

def ekstrak_hakim(daftar_baris):
    """Ambil nama hakim. Tiga aturan dicoba berurutan; hasil pertama yang
    1) 'oleh kami, X sebagai Hakim Ketua ...'
    2) blok tanda tangan 'Panitera Pengganti, Hakim, ...' + baris nama di
    3) cadangan: 'X, S.H., Hakim Pengadilan Negeri Surabaya'"""

```

```

def aturan_oleh_kami():
    for i, baris in enumerate(daftar_baris):
        if not POLA_KELEBIH.search(baris):
            continue
        kalimat = " ".join(daftar_baris[i:i + 7])
        cocok = re.search(r"(?i)(?:oleh\s+kami\s*[:,\]?|oleh,?)\s*(.*?r(?:masing-?\s*masing\s+)?sebagai\s+hakim\s+kalimat)

        if cocok:
            ketua = (POLA_NAMA.findall(cocok.group(1)) or [None])[0]
            sisa = kalimat[cocok.end():]
            if "masing-masing sebagai" in sisa:
                sisa = sisa.split("masing-masing sebagai")[0]
            anggota = POLA_NAMA.findall(sisa)
            if ketua or anggota:
                return {"ketua": ketua, "anggota": anggota,
                        "tunggal": None, "cara": "oleh-kami"}
        if re.search(r"(?i)hakim\s+tunggal", kalimat):
            nama = POLA_NAMA.findall(kalimat)
            if nama:
                return {"ketua": None, "anggota": [],
                        "tunggal": nama[0], "cara": "oleh-kami-tunggal"}

    return None

def aturan_blok_ttd():
    for i, baris in enumerate(daftar_baris):
        if not POLA_ANCHOR.search(baris):
            continue
        tunggal = bool(re.search(r"(?i)hakim\s+tunggal", baris))
        for berikut in daftar_baris[i + 1:i + 6]:
            if POLA_SISA.search(berikut) or POLA_TTD.match(berikut.st
            continue
            nama = POLA_NAMA.findall(berikut)
            if not nama:
                continue
            kecil = baris.lower()
            if tunggal:
                return {"ketua": None, "anggota": [],
                        "tunggal": nama[0], "cara": "ttd-tunggal"}
            if "ketua" in kecil and "anggota" in kecil:
                if re.search(r"(?i)anggota.*ketua", kecil):
                    ketua = nama[1] if len(nama) > 1 else None
                    return {"ketua": ketua, "anggota": [nama[0]],
                            "tunggal": None, "cara": "ttd-majelis"}
                return {"ketua": nama[0], "anggota": nama[1:],
                        "tunggal": None, "cara": "ttd-majelis"}
            if "panitera" in kecil and "anggota" not in kecil:
                return {"ketua": None, "anggota": [],
                        "tunggal": nama[-1], "cara": "ttd-tunggal"}
            if len(nama) >= 2:
                return {"ketua": nama[0], "anggota": nama[1:],
                        "tunggal": None, "cara": "ttd-majelis"}
            return {"ketua": None, "anggota": [],
                    "tunggal": nama[0], "cara": "ttd-tunggal"}

    return None

def aturan_hakim_kalimat():
    for i, baris in enumerate(daftar_baris):
        kalimat = " ".join(daftar_baris[i:i + 7])
        if POLA_KELEBIH.search(kalimat):

```

```

        continue # sudah ditangani aturan_oleh_kami
    cocok = POLA_TUNGGAH_KALIMAT.search(kalimat)
    if cocok:
        nama = POLA_NAMA.findall(cocok.group(1))
        if nama:
            return {"ketua": None, "anggota": [],
                    "tunggal": nama[-1], "cara": "tunggal-kalimat"}
    return None

def bersihkan_nama(nama):
    """Buang sisa gelar di depan nama (mis. "M.H Teguh" -> "Teguh")."""
    for _ in range(2):
        baru = re.sub(r"^(?:S\.?H\.?|M\.?H\.?|M\.?Hum\.?|Drs?\.?|Dr\."
                      "", nama).strip()
        if baru == nama:
            break
        nama = baru
    return nama

for aturan in (aturan_oleh_kami, aturan_blok_ttd, aturan_hakim_kalima):
    hasil = aturan()
    if hasil:
        if hasil["ketua"]:
            hasil["ketua"] = bersihkan_nama(hasil["ketua"])
        if hasil["tunggal"]:
            hasil["tunggal"] = bersihkan_nama(hasil["tunggal"])
        hasil["anggota"] = [bersihkan_nama(n) for n in hasil["anggota"]]
        return hasil
    return {"ketua": None, "anggota": [], "tunggal": None, "cara": "tidak"}

```

```

In [4]: # ===== TAHAP 1 - FUNGSI UTAMA: audit korpus & rencana aksi =
#   audit_korpus()          -> {nama_pdf: info}
#   susun_rencana(info)     -> (rencana, nomor)

```

```

def audit_korpus():
    """Proses semua PDF (sumber + yang sudah disisihkan), kembalikan {nama: info}
    Menyertakan _EXCLUDE/ supaya manifest tetap 273 baris saat notebook d
    daftar = sorted(p.name for p in FOLDER_SUMBER.glob("*.pdf"))
    daftar += sorted(p.name for p in FOLDER_SISIH.glob("*.pdf"))
    if BATAS_FILE:
        daftar = daftar[:BATAS_FILE]

    info = {}
    for urutan, nama in enumerate(daftar, 1):
        lokasi = FOLDER_SUMBER / nama
        if not lokasi.exists():
            lokasi = FOLDER_SISIH / nama

        baris, hakim = proses_satu_pdf(lokasi)
        teks = "\n".join(baris)

        # jumlah halaman lewat pdfinfo (cepat, tanpa mengekstrak teks)
        keluar = subprocess.run(["pdfinfo", str(lokasi)],
                                capture_output=True, text=True).stdout
        cocok = re.search(r"Pages:\s+(\d+)", keluar)

        info[nama] = {
            "md5": hashlib.md5(Path(lokasi).read_bytes()).hexdigest(), #
            "halaman": int(cocok.group(1)) if cocok else 0,

```

```

        "baris": baris,
        "karakter": len(teks),
        "hakim": hakim,
    }
    if urutan % 25 == 0:
        print(f" ... {urutan}/{len(daftar)} file")
    return info

def susun_rencana(info):
    """Tentukan aksi tiap file berdasar ISI dokumen (bukan daftar hafalan

    Return:
        rencana : {nama: (aksi, alasan, nama_baru)}, aksi = 'normal' | 'sis
        nomor   : {nama: (nomor_header, nomor_footer, cocok)} -> dipakai un
    """
    # peta md5 -> nama kanonis (nama yang bukan 'putusan_*' diutamakan)
    peta_md5 = {}
    for nama in sorted(info):
        md5 = info[nama]["md5"]
        if md5 not in peta_md5:
            peta_md5[md5] = nama
        elif (peta_md5[md5].lower().startswith("putusan_")
              and not nama.lower().startswith("putusan_")):
            peta_md5[md5] = nama

    # seragamkan untuk perbandingan (abaikan spasi/titik/besar-kecil)
    bersih = lambda s: re.sub(r"^[A-Z0-9]+", "", s.upper())

    rencana, nomor = {}, {}
    for nama in info:
        data = info[nama]
        baris = data["baris"]

        # --- nomor perkara resmi di 12 baris pertama (blok judul) ---
        # prioritas: baris berlabel 'Nomor :' (bukan 'Jo Nomor' / 'Regist
        header = None
        awal = baris[:12]
        for b in awal:
            if b.startswith("Nomor :"):
                cocok = POLA_NOMOR.search(b)
                if cocok:
                    header = (cocok.group(1), cocok.group(2), cocok.group
                    break
        if header is None:
            for b in awal:
                cocok = POLA_NOMOR.search(b)
                if cocok:
                    header = (cocok.group(1), cocok.group(2), cocok.group
                    break

        # --- 'Penetapan/Putusan Nomor ...' di footer halaman ---
        footer = None
        for b in baris[-15:]:
            if re.search(r"(?i)(penetapan|putusan).*nomor", b):
                cocok = POLA_NOMOR.search(b)
                if cocok:
                    footer = (cocok.group(1), cocok.group(2), cocok.group
                    break

```

```

# bandingkan nomor+jenis+tahun saja; ekor kalimat footer ("tertan
cocok_nomor = ""
if header and footer:
    h = (bersih(header[0]), bersih(header[1]), header[2])
    f = (bersih(footer[0]), bersih(footer[1]), footer[2])
    cocok_nomor = "ya" if h == f else "tidak"
    nomor[nama] = (header, footer, cocok_nomor)

# --- tentukan aksi ---
# '1031_Pdt.G_2026_PN Sby.pdf' -> ('1031', 'Pdt.G', '2026')
cocok_file = POLA_NAMA_FILE.search(nama)
pecah = cocok_file.groups() if cocok_file else None

if peta_md5[data["md5"]] != nama:
    aksi = ("sisihkan", f"duplikat byte-identik dari {peta_md5[da
elif data["halaman"] <= 1 and data["karakter"] < BATAS_TANPA_TEKS
    aksi = ("sisihkan", "hasil scan tanpa layer teks (butuh OCR)"
elif pecah and header:
    nomor_f, jenis_f, tahun_f = bersih(pecah[0]), bersih(pecah[1]
    nomor_h, jenis_h, tahun_h, adil_h = (bersih(header[0]), bersi
        header[2], bersih(header

    if nomor_f != nomor_h:
        aksi = ("sisihkan", f"nomor nama file ({nomor_f}) != nomo
    elif "SBY" not in adil_h and adil_h:
        aksi = ("sisihkan", f"putusan pengadilan lain ({adil_h})"
    elif tahun_f != tahun_h:
        baru = nama.replace(f"_{tahun_f}_", f"_{tahun_h}_", 1)
        aksi = ("rename", f"tahun nama file ({tahun_f}) -> tahun
    elif jenis_f != jenis_h:
        aksi = ("normal", f"flag: jenis nama file ({jenis_f}) !=
    else:
        aksi = ("normal", "", None)
    elif pecah and not header:
        aksi = ("normal", "flag: nomor tidak terbaca di header", None
    else:
        aksi = ("normal", "", None)
    rencana[nama] = aksi

return rencana, nomor

```

```

In [5]: # ===== TAHAP 1 - FUNGSI UTAMA: eksekusi, manifest, validasi
# jalankan_aksi(info, rencana) -> {nama: (nama_akhir, status, a
# tulis_manifest(info, rencana, nomor) -> daftar baris manifest (dict)
# validasi(info, rencana, data) -> mencetak rekap
# jalankan_pembersihan() -> menjalankan seluruh tahap 1

def jalankan_aksi(info, rencana):
    """Eksekusi rencana (pindah ke _EXCLUDE, rename PDF, tulis TXT bersih
    Idempoten. Berhenti bila file bermasalah melebihi BATAS_ABORT."""
    bermasalah = sum(1 for v in rencana.values() if v[0] != "normal")
    if bermasalah > BATAS_ABORT:
        raise SystemExit(f"BATAL: {bermasalah} file bermasalah melebihi b

    hasil = {}
    for nama in sorted(rencana):
        aksi, alasan, baru = rencana[nama]

        if aksi == "sisihkan":
            asal, tujuan = FOLDER_SUMBER / nama, FOLDER_SISIH / nama

```

```

        if tujuan.exists():
            status = "sudah-disana"
        elif DRY_RUN:
            status = "dry-run"
        else:
            FOLDER_SISIH.mkdir(exist_ok=True)
            shutil.move(str(asal), str(tujuan))
            status = "dipindah"
        hasil[nama] = ("exclude", status, alasan)
        continue

# aksi 'rename' atau 'normal' -> keduanya menulis TXT bersih
status_rename = None
if aksi == "rename":
    asal, tujuan = FOLDER_SUMBER / nama, FOLDER_SUMBER / baru
    if not asal.exists():
        status_rename = "sudah-rename"
    elif tujuan.exists():
        status_rename = "batal-ada-kembar"
    elif DRY_RUN:
        status_rename = "dry-run"
    else:
        asal.rename(tujuan)
        status_rename = "direname"

nama_txt = baru if aksi == "rename" else nama
FOLDER_BERSIH.mkdir(exist_ok=True)
tujuan_txt = FOLDER_BERSIH / ("T-" + Path(nama_txt).stem + ".txt")
if not DRY_RUN:
    tujuan_txt.write_text("\n".join(info[nama]["baris"]) + "\n",

    if aksi == "rename":
        hasil[nama] = (baru, f"{status_rename} + {tujuan_txt}", alasan)
    else:
        hasil[nama] = (nama, str(tujuan_txt), alasan)
return hasil

def tulis_manifest(info, rencana, nomor):
    """Susun & tulis _MANIFEST.csv (aktif + rename + exclude) dan _EXCLUDE
    teks_nomor = lambda p: f"{p[0]}/{p[1]}/{p[2]}" if p else "" # ('100'

    baris_data = []
    for nama in sorted(info):
        data = info[nama]
        aksi, alasan, baru = rencana[nama]
        header, footer, cocok = nomor[nama]
        akhir = baru if aksi == "rename" else nama
        status = {"sisihkan": "exclude", "rename": "rename", "normal": "a
        hakim = data["hakim"]

    if re.search(r"-{3,}.*S\\.?.?H", " ".join(data["baris"][-30:])):
        alasan = (alasan + "; " if alasan else "") + "flag: nama haki

    baris_data.append({
        "file_pdf": akhir, "nama_asli": nama, "status": status, "alas
        "nomor_header": teks_nomor(header), "nomor_footer": teks_nomo
        "nomor_cocok": cocok,
        "tahun": header[2] if header else "", "jenis": header[1] if h
        "pengadilan": (header[3].strip() if header else ""),

```

```

        "hakim_ketua": hakim["ketua"] or "",
        "hakim_anggota": "; ".join(hakim["anggota"]),
        "hakim_tunggal": hakim["tunggal"] or "", "cara_hakim": hakim[
        "halaman_pdf": data["halaman"], "jumlah_baris": len(data["bar
        "jumlah_karakter": data["karakter"],
    })

    if DRY_RUN:
        return baris_data
    with open(FILE_MANIFEST, "w", newline="", encoding="utf-8") as berkas
        penulis = csv.DictWriter(berkas, fieldnames=KOLOM_MANIFEST)
        penulis.writeheader()
        penulis.writerows(baris_data)
    alasan_exclude = [f"{b['nama_asli']}: {b['alasan']}" for b in baris_d
    (FOLDER_SISIH / "_ALASAN.txt").write_text("\n".join(alasan_exclude) +
    return baris_data

def validasi(info, rencana, data):
    """Cetak rekap: file, karakter, sisa noise, cakupan trigger, file tan
    aktif = [n for n, v in rencana.items() if v[0] != "sisihkan"]
    total_karakter = sum(info[n]["karakter"] for n in aktif)
    print(f"File aktif : {len(aktif)}")
    print(f"File sisihan: {len(info) - len(aktif)}")
    print(f"Total karakter bersih: {total_karakter:,}")

    print("\nSisa noise di CLEAN_TXT/ (harus 0 semua):")
    for pola in NOISE:
        kena = sum(sum(1 for b in info[n]["baris"] if re.search(pola, b,
        print(f" {kena:6d} {pola}")

    print("\nCakupan trigger rule (jumlah file yang cocok):")
    for nama_trigger, pola in TRIGGER.items():
        kena = sum(1 for n in aktif if any(re.search(pola, b, re.I) for b
        print(f" {kena:4d}/{len(aktif)} {nama_trigger}")

    print("\nFile tanpa hakim:")
    for b in data:
        if b["status"] == "aktif" and not (b["hakim_ketua"] or b["hakim_a
        print(f" {b['file_pdf']}")

    print("\nSampel 30 baris pertama (1 pidana, 1 gugatan, 1 permohonan):
    for contoh in ["1002_Pid.Sus-LH_2026_PN Sby.pdf", "108_Pdt.G_2026_PN
        "2296_Pdt.P_2026_PN Sby.pdf"]:
        if contoh in info and rencana[contoh][0] != "sisihkan":
            print(f"\n===== {contoh} =====")
            for baris in info[contoh]["baris"][:30]:
                print(" ", baris[:100])

def jalankan_pembersihan():
    """Jalankan seluruh tahap 1: audit -> rencana -> aksi -> manifest ->
    print("Mulai audit korpus...")
    info = audit_korpus()
    print(f"Selesai: {len(info)} file diaudit.")

    rencana, nomor = susun_rencana(info)
    print(f"{'file':38s} {'aksi':10s} alasan")
    for nama in sorted(rencana):
        aksi, alasan, baru = rencana[nama]
```

```

        if aksi != "normal" or alasan:
            ekstra = f" -> {baru}" if baru else ""
            print(f"{nama:38s} {aksi:10s} {alasan}{ekstra}")
    n_bermasalah = sum(1 for v in rencana.values() if v[0] != "normal")
    print(f"\nFile bermasalah: {n_bermasalah} dari {len(rencana)}")

    hasil = jalankan_aksi(info, rencana)
    n_aktif = sum(1 for nama, (akhir, _, _) in hasil.items() if not str(a
    print(f"Selesai. File aktif: {n_aktif}, disisihkan: {len(hasil) - n_a

    data = tulis_manifest(info, rencana, nomor)
    print(f"Manifest ditulis: {len(data)} baris -> {FILE_MANIFEST}")

    validasi(info, rencana, data)
    return info, rencana, hasil, data

```

Jalankan tahap 1

```

In [6]: # ===== JALANKAN TAHAP 1 =====
        CACHE, RENCANA, HASIL, DATA = jalankan_pembersihan()

```

Mulai audit korpus...

... 25/273 file
 ... 50/273 file
 ... 75/273 file
 ... 100/273 file
 ... 125/273 file
 ... 150/273 file
 ... 175/273 file
 ... 200/273 file
 ... 225/273 file
 ... 250/273 file

Selesai: 273 file diaudit.

file	aksi	alasan
1031_Pdt.G_2026_PN Sby.pdf	sisihkan	nomor nama file (1031) != nomor isi (100)
17_Pdt.Sus-Pailit-GLL_2025_PN.Niaga Sby.pdf	normal	flag: jenis nama file (PDTSUSPAILITGLL) != jenis isi (PDTSUSGUGATANLAINLAIN)
3162_Pid.B_2017_PN SBY.pdf	sisihkan	nomor nama file (3162) != nomor isi (3150)
3749_Pid.B_2017_PN SBY.pdf	sisihkan	nomor nama file (3749) != nomor isi (113)
3882_Pid.Sus_2017_PN SBY.pdf	normal	flag: jenis nama file (PIDSUS) != jenis isi (PIDB)
527_Pid.Sus_2018_PN SBY.pdf	sisihkan	nomor nama file (527) != nomor isi (359)
748_Pid.C_2025_PN Sby.pdf	sisihkan	hasil scan tanpa layer teks (butuh OCR)
946_Pdt.G_2025_PN Sby.pdf	normal	flag: nomor tidak terbaca di header
putusan_186_pdt.g_2026_pn_sby_20260930172538.pdf	sisihkan	duplikat byte-identik dari 186_Pdt.G_2026_PN Sby.pdf
putusan_227_pdt.g_2026_pn_sby_20261001175526.pdf	sisihkan	duplikat byte-identik dari 227_Pdt.G_2026_PN Sby.pdf
putusan_2296_pdt.p_2026_pn_sby_20261002062257.pdf	sisihkan	duplikat byte-identik dari 2296_Pdt.P_2026_PN Sby.pdf
putusan_2569_pdt.p_2026_pn_sby_20261002062209.pdf	sisihkan	duplikat byte-identik dari 2569_Pdt.P_2026_PN Sby.pdf
putusan_2594_pdt.p_2026_pn_sby_20261002063444.pdf	sisihkan	duplikat byte-identik dari 2594_Pdt.P_2026_PN Sby.pdf
putusan_2674_pdt.p_2026_pn_sby_20261002062020.pdf	sisihkan	duplikat byte-identik dari 2674_Pdt.P_2026_PN Sby.pdf
putusan_3278_pid.sus_2017_pn_sby_20261002061355.pdf	sisihkan	duplikat byte-identik dari 3278_Pid.Sus_2017_PN SBY.pdf
putusan_55_pid.sus-tpk_2026_pn_sby_20261002063524.pdf	sisihkan	duplikat byte-identik dari 55_Pid.Sus-TPK_2026_PN Sby.pdf
putusan_6_pdt.sus-hki_merek_2026_pn_niaga_sby_20261001151239.pdf	sisihkan	duplikat byte-identik dari 6_Pdt.Sus-HKI_Merek_2026_PN Niaga Sby.pdf
putusan_71_pdt.sus-pkpu_2026_pn_niaga_sby_20261001151203.pdf	sisihkan	duplikat byte-identik dari 71_Pdt.Sus-PKPU_2026_PN Niaga Sby.pdf

File bermasalah: 15 dari 273

Selesai. File aktif: 258, disisihkan: 15.

Manifest ditulis: 273 baris -> _MANIFEST.csv

File aktif : 258

File sisihan: 15

Total karakter bersih: 11,069,896

Sisa noise di CLEAN_TXT/ (harus 0 semua):

```
0 ^Mahkamah Agung Republik Indonesia$
0 mahkamahagung\go\id
```

0 ^Disclaimer\$
 0 ^Direktori Putusan Mahkamah Agung Republik Indonesia\$

Cakupan trigger rule (jumlah file yang cocok):

95/258 nama (lengkap|terdakwa) :
 99/258 menyatakan terdakwa
 100/258 menjatuhkan pidana
 140/258 diputuskan dalam
 160/258 hakim ketua

File tanpa hakim:

Sampel 30 baris pertama (1 pidana, 1 gugatan, 1 permohonan):

===== 1002_Pid.Sus-LH_2026_PN Sby.pdf =====

PUTUSAN

Nomor : 1002/Pid.Sus-LH/2026/PN Sby

DEMI KEADILAN BERDASARKAN KETUHANAN YANG MAHA ESA

Pengadilan Negeri Surabaya yang mengadili perkara pidana dengan
 acara pemeriksaan biasa dalam tingkat pertama menjatuhkan putusan sebaga

i

berikut dalam perkara Terdakwa :

1. Nama lengkap :

HENDRIK SETIAWAN BIN (alm) ABDUL

HALIM;

2. Tempat lahir : Jember;

3. Umur/tanggal lahir : 32

Tahun / 29 September 1993;

4. Jenis Kelamin : Laki-laki;

5. Kebangsaan :

Indonesia;

6. Tempat tinggal : Komp.

Agraria 2 Gg. 4A RT.024/RW.002 Kel. Basirih

Kec. Banjarmasin Barat Kota Banjarmasin Prov.

Kalimantan Selatan;

7. Agama : Islam;

8. Pekerjaan : Wiraswasta

(Sopir);

Terdakwa ditangkap sejak tanggal 17 April 2026 sampai dengan tanggal
 18 Mei 2026;

Terdakwa ditahan dalam tahanan Rumah Tahanan Negara oleh :

1. Penyidik sejak tanggal 18 April 2026 sampai dengan tanggal 07 Mei 202

6;

2. Perpanjangan Penuntut Umum sejak tanggal 08 Mei 2026 sampai dengan
 tanggal 16 Juni 2026;

3. Penuntut Umum sejak tanggal 09 Juni 2026 sampai dengan tanggal 28
 Juni 2026;

===== 108_Pdt.G_2026_PN Sby.pdf =====

PUTUSAN

Nomor : 108/Pdt.G/2026/PN Sby

DEMI KEADILAN BERDASARKAN KETUHANAN YANG MAHA ESA

(1.1) Pengadilan Negeri Surabaya yang mengadili perkara perdata pada tin
 gkat

pertama, telah menjatuhkan putusan sebagai berikut dalam perkara gugatan
 antara:

PT. WIRALOGAM , Badan hukum berbentuk Perseroan Terbatas yang

didirikan berdasarkan hukum Republik Indonesia dengan Akta Perseroan

Terbatas "PT. Aneka Logam Utama" Nomor : 154 tertanggal 26 Februari 1987

yang telah didaftarkan di Kepaniteraan Pengadilan Negeri Surabaya tangga

27

Agustus 1990 di bawah nomor : 929/1990 yang berkedudukan hukum di Kota Surabaya dan beralamat kantor di Jalan Kalimas Timur Nomor 204 – 208, Kelurahan Nyamplungan, Kecamatan Pabean Cantian, Kota Surabaya, beserta perubahan-perubahannya, terakhir dengan Akta Berita Acara Nomor 21 tertanggal 26 Agustus 2013 yang dibuat di hadapan Notaris Tri Avianti Merpatiningsih, S.H. di Kota Surabaya dan telah disahkan berdasarkan Keputusan Menteri Hukum dan HAM Republik Indonesia Nomor : AHU-AH.01.10-39158 tanggal 18 September 2013. Dalam hal ini diwakili oleh To

ny

Sutanto Alim, selaku Direktur Utama PT. Wiralogam, dan memberikan Kuasa kepada Saroha Orlando Oktavianus Siahaan, S.H., dkk, Para Advokat/Pengacara, Konsultan Hukum pada Kantor Hukum JUSTICIA yang beralamat di Santorini Townsquare – Suite Olympus, Jalan Ronggolawe 2A, Kelurahan Dr. Soetomo, Kecamatan Tegalsari, Kota Surabaya, Email sarohasiahaan5@gmail.com , berdasarkan Surat Kuasa Khusus tertanggal 05 Januari 2026, sebagai PENGGUGAT KONVENSI/ TERGUGAT REKONVENSI ;

Lawan:

1. KALEB PRAYUDI ANTONIUS , Laki-laki, Warga Negara Indonesia, Tempat dan Tanggal Lahir : Surabaya, 7 Juli 1964, yang dahulu bertempat tinggal

di

Jalan Kertajaya Indah Timur XVII Nomor: 50 RT 002 RW 006, Kelurahan Gebang Putih, Kecamatan Sukolilo, Kota Surabaya, dan sekarang diketahui

===== 2296_Pdt.P_2026_PN Sby.pdf =====

PENETAPAN

Nomor : 2296/Pdt.P/2026/PN Sby

DEMI KEADILAN BERDASARKAN KETUHANAN YANG MAHA ESA

(1.1) Pengadilan Negeri Surabaya yang memeriksa dan memutus perkara perdata pada tingkat pertama, telah menjatuhkan penetapan sebagai beriku

t

dalam permohonan yang diajukan oleh :

AMELIA YASEH PRIJONO, bertempat tinggal di Grating Baru 4/8 Kota Kel. Simokerto Kec. Simokerto Kota Surabaya, email ameliayph2@gmail.com , sebagai Pemohon.

(1.2) Pengadilan Negeri tersebut;

Membaca berkas perkara beserta surat-surat yang bersangkutan; mendengar permohonan Pemohon;

Memperhatikan bukti-bukti yang diajukan Pemohon;

2. TENTANG DUDUK PERKARA

(2.1) Menimbang bahwa Pemohon dengan surat permohonan tanggal 28 Juli 2026 yang diterima dan didaftarkan di Kepaniteraan Pengadilan Negeri Surabaya pada tanggal 30 Juli 2026 dalam Register Nomor 2296/Pdt.P/2026/

PN

Sby, telah mengajukan permohonan sebagai berikut :

1. Bahwa Pemohon merupakan Warga Negara Indonesia dan tercatat di daftar kependudukan dengan nama Amelia Yaseh Prijono sebagaimana tercatat dalam Kartu Tanda Penduduk (KTP) nomor 3578116605710001 dikeluarkan oleh Kepala Dinas Kependudukan dan Pencatatan Sipil Kota Surabaya tertanggal 02 - 07 - 2012;

2. Bahwa Pemohon telah terdaftar dalam Kartu Keluarga (KK) atas nama Amelia Yaseh Prijono sebagaimana Kartu Keluarga No. 3578110101082836 yang dikeluarkan oleh Kantor Dinas Kependudukan dan Pencatatan Sipil Kota Surabaya tertanggal 23-01-2024;

3. Bahwa Pemohon yang bernama Amelia Yaseh Prijono telah tercatat Akte Kelahiran nomor 3940/ 1971 yang dikeluarkan oleh Pengadilan Negeri Hal. 1 dari 14 hal Penetapan Nomor 2296/Pdt.P/2026/PN Sby

Ringkasan hasil

Fungsi `validasi()` mencetak semuanya: jumlah file aktif vs disisihkan, sisa noise (harus nol), cakupan tiap trigger rule, daftar file tanpa hakim, dan sampel teks untuk inspeksi manual.

File yang perlu perhatian manusia ada di kolom `alasan` pada `_MANIFEST.csv` (mis. `flag: ...`). Khusus kolom hakim: cek 20 baris dengan `cara_hakim = tunggal-kalimat` atau `ttd-tunggal` terhadap blok tanda tangan di PDF aslinya.

BAGIAN 10 — EKSTRAKSI 15 ENTITAS DARI CLEAN_TXT

Tujuan: melanjutkan `clean_pdf.ipynb` menjadi satu file pipeline.

- Input: `CLEAN_TXT/` (258 file .txt, prefix T-)
- Output: `OUTPUT_CLEAN/` (per file 0-*.txt berisi entitas terstruktur) + `OUTPUT_CLEAN/entitas_258.csv` (rangkuman 258 data)
- Desain: beberapa fungsi utama (rule-based), regex dikumpulkan di cell pola, komentar Bahasa Indonesia.
- Nilai kosong memakai `-` ; kolom keterangan menjelaskan alasan setiap kekosongan.

```
In [7]: # ===== TAHAP 2 - POLA REGEX & KONSTANTA =====
POLA_BARIS_NOMOR = re.compile(r"(?i)^\s*(?:[IVX]+\.\s*)?(?:putusan\s+|pen
POLA_NOMOR_PUTUSAN = re.compile(r"(?i)(\d{1,5}|-\{5,\})\s*/?\s*([A-Za-z][\w
POLA_LABEL_NAMA = re.compile(r"(?i)(?:^|\b)(?:[IVX0-9]+\.\s*)?(?:nama\s+(
POLA_BATAS_IDENTITAS = re.compile(r"(?i)terdakwa\s+dita(?:han|ngkap)|tela
POLA_LABEL_LAPANGAN = re.compile(r"(?i)^\s*(?:[IVX0-9]+\.\s*)?(?:tempat(?
POLA_AWAL_TUNTUTAN = re.compile(r"(?i)tuntutan\s+(?:pidana|jaksa|penuntut
POLA_AKHIR_TUNTUTAN = re.compile(r"(?i)Setelah mendengar(?:pembelaan|per
POLA_MENGADILI = re.compile(r"(?i)^\s*(?:\d+\.\s*)?M\s*E\s*N\s*G\s*A\s*D\
POLA_PENUTUP = re.compile(r"(?i)Demikian(?:lah)?[,,\s]+(?:?:putusan|penet
POLA_NOMOR_AMAR = re.compile(r"^\s*(\d+)\s*(.)\s*(.*)$")
POLA_GARIS_AMAR = re.compile(r"(?i)^\s*[-\.\s]+(?:=.*\b(menyatakan|menjatuh
POLA_BARIS_SAMPAH_AMAR = re.compile(r"(?i)^\s*(?:Halaman\b|Hal\.\s*\d+|P
POLA_SAMPAH_HALAMAN = re.compile(r"(?i)\bHal(?:aman)?\.\s*\d+|\b\d+\s*da
FRAGMEN_NAMA = r"[A-ZÄ-Ž][\w.'\"-]*"
TOKEN_GELAR = r"(?:[A-Z][\w]*\.(?:[A-Z\w.]*\.)?|S\.?H\.?|M\.?H\.?|M\.?Hu
PEMISAH_GELAR = fr"(?:[\s,]*,[\s,]*|\s+(?={TOKEN_GELAR}\b))"
RANTAI_GELAR = fr"(?:([\s,]*,[\s,]*|\s+(?={TOKEN_GELAR}\b))){TOKEN_GELAR
TEKS_NAMA = fr"{FRAGMEN_NAMA}(?:\s+{FRAGMEN_NAMA})*?{PEMISAH_GELAR}{TOKEN
POLA_NAMA_BERGELAR = re.compile(fr"\b({TEKS_NAMA})")
POLA_PANEL_HAKIM = re.compile(r"(?s)(?i:oleh\s+kami|oleh)\s*[,:;]?\s*" fr
POLA_PANEL_HAKIM_ADHOC = re.compile(r"(?s)(?i:oleh\s+kami|oleh)\s*[,:;]?\
POLA_PANEL_TANPA_LABEL = re.compile(r"(?s)(?i:oleh\s+kami|oleh)\s*[,:;]?\
POLA_PANITERA = re.compile(fr"(?s)(?i:didampingi|dibantu|dihadiri)(?:(?i:
POLA_JPU = re.compile(fr"(?s)(?i:dihadiri|hadiri|dihadapan)(?:(?i:\s+pula
POLA_JPU_POLOS = re.compile(fr"(?s)(?i:dihadiri|hadiri|dihadapan)(?:(?i:\
POLA_TANGGAL = re.compile(r"(?i)pada\s+(?:hari\s*:\s*)?((?:[A-Za-z']\s*)
POLA_HUKUMAN_KHUSUS = re.compile(r"(?i)\bpidana mati\b|\bhukuman mati\b|\\
```

```

SATUAN_WAKTU = {"tahun", "bulan", "minggu", "hari"}
KATA_BERHENTI_LAMA = {"dikurangi", "dikurangkan", "dipotong", "potong", "
POLA_PANITERA_APOSISI = re.compile(fr"(?s)(?:[,;:]|\\btersebut\\b)\\s*(?P<na

PETA_JENIS = {"Pid.B": "pidana", "Pid.Sus": "pidana", "Pid.Sus-LH": "pidana", "
BERLAKE_PIDANA = {"nomor_putusan", "nama_terdakwa_1", "nama_terdakwa_2", "na
BERLAKE_UMUM = {"nomor_putusan", "tanggal_putusan", "hakim_ketua", "hakim_an

PETA_BULAN = {"januari": "Januari", "februari": "Februari", "pemberi": "Februa

```

```

In [8]: # ===== TAHAP 2 - ALAT BANTU (dipakai berulang oleh fungsi ut
def rapikan_teks(teks):
    """Rapikan spasi; buang ; , : di ujung, tetapi pertahankan titik gela
    if not teks:
        return None
    teks = re.sub(r"\s+", " ", teks).strip().rstrip(";;. ").rstrip(";; :
    if len(teks) >= 2 and teks[0] in "\"'" and teks[-1] in "\"'":
        teks = teks[1:-1].strip() # buang tanda kutip pembungkus luar
    elif teks[:1] in "\"'":
        teks = teks[1:].strip() # kutip pembuka tanpa penutup
    return teks or None

def rapikan_nama(nama):
    """Rapikan nama: buang koma ganda dan beri spasi sesudah koma."""
    nama = rapikan_teks(nama)
    if not nama:
        return None
    nama = re.sub(r"(?<=[a-zà-ž])\\. (?=[A-Z])", " ", nama)
    return re.sub(r", (?=[^\s\d])", " ", nama)

def himpunan_berlaku(jenis):
    """Pidana memakai 15 entitas; selain itu hanya 6 entitas umum."""
    return set(BERLAKE_PIDANA) if jenis == "pidana" else set(BERLAKE_UMUM

def buang_baris_sampah(daftar):
    """Buang baris kosong dan footer halaman ('Halaman 8', 'Hal. 26 dari
    hasil = []
    for x in daftar:
        if not x.strip():
            continue
        rendah = x.lower()
        footer = bool(POLA_BARIS_SAMPAH_AMAR.match(x) or POLA_SAMPAH_HALA
                    or ("halaman" in rendah and ("putusan" in rendah or
                    or re.match(r"^\s*hal"

        if not footer:
            hasil.append(x)
    return hasil

def ambil_item_amar(bagian, nomor, frasa=None):
    """Ambil satu amar bernomor ('1.', '1)', '2. ...' di tengah baris, '-
    nomor = str(nomor)
    kata_amar = r"(?:menyatakan|menjatuhkan|menetapkan|menghukum|membeban
    if frasa:
        kunci = frasa.lower()
        for i, x in enumerate(bagian):
            if kunci in x.lower():

```

```

        jangkau = range(max(0, i - 5), min(len(bagian), i + 6))
        tepat = [k for k in jangkau if re.match(rf"^\s*{nomor}[.]"
garis = [k for k in jangkau if POLA_GARIS_AMAR.match(bagi
target = tepat + [k for k in garis if k not in tepat]
if not target:
    continue
k = target[0]
mulai = min(i, k)
akhir = len(bagian)
for j in range(max(i, k) + 1, len(bagian)):
    if POLA_NOMOR_AMAR.match(bagian[j]):
        akhir = j
        break
    else:
        for j in range(max(i, k) + 1, len(bagian)):
            if POLA_GARIS_AMAR.match(bagian[j]):
                akhir = j
                break
        return " ".join(buang_baris_sampah(bagian[mulai:akhir]))
for i, x in enumerate(bagian):
    cocok = POLA_NOMOR_AMAR.match(x)
    if cocok and cocok.group(1) == nomor:
        akhir = len(bagian)
        for j in range(i + 1, len(bagian)):
            if POLA_NOMOR_AMAR.match(bagian[j]) or POLA_GARIS_AMAR.ma
                akhir = j
                break
        return " ".join(buang_baris_sampah(bagian[i:akhir]))
return None

def ambil_perbuatan(teks):
    """Ambil nama perbuatan pidana sesudah 'bersalah melakukan' (dan vari
    pola = re.search(r"(?i)bersalah\s+melakukan\s+(.*)", teks)
    if not pola:
        pola = re.search(r"(?i)\bmelakukan\b\s+(.*)", teks)
    if not pola: # varian: '... menurut hukum dalam hal perbuatan X ...'
        pola = re.search(r"(?i)terbukti\b.{0,120}?menurut hukum\s+dalam h
    if not pola:
        return None
    depan = re.split(r"(?i)\s*,?\s*sebagaimana|;\|bkarena\b|\bmelanggar\b
    depan = re.sub(r"^(?:[A-ZÄ-Ž][A-ZÄ-Ž.'\s-]*\s+){1,3}(?=[Tt]indak\s+[P
    depan = re.sub(r"(?i)^(?:perbuatan\s*,\s*|tindak\s+pidana\s+|pidana\s
    depan = rapikan_teks(depan)
    if depan and depan.lower() in {"tindak pidana", "pidana", "perbuatan"
        return None # hanya label generik, bukan nama perbuatannya
    return depan

def ambil_lama_pidana(teks):
    """Ambil durasi penjara sesudah kata 'selama' ('1 tahun dan 6 bulan')
    if not teks:
        return None
    khusus = POLA_HUKUMAN_KHUSUS.search(teks)
    if khusus:
        return rapikan_teks(khusus.group(0))
    for awal in re.finditer(r"(?i)\bs(?:elama|leama)\b\s*:\s*({0,300})"
        # rangkai token angka + satuan waktu sampai kata penghenti
        token = re.findall(r"\(|\)|,|;|:|\d+(?:[.,]\d+)?|[A-Za-zÄ-Ž]+", a
        potongan = []

```

```

ada_satuan = False
i = 0
while i < len(token):
    kata = token[i]
    rendah = kata.casefold()
    if kata in {",", ";", ":"}:
        break
    if rendah in KATA_BERHENTI_LAMA:
        break
    if rendah == "dan" or rendah == "clan": # 'clan' = salah ket
        berikut = token[i + 1] if i + 1 < len(token) else ""
        if re.fullmatch(r"\d+(?:[.]\d+)?", berikut):
            potongan.append(kata)
            i += 1
            continue
        break
    potongan.append(kata)
    if rendah in SATUAN_WAKTU:
        ada_satuan = True
    i += 1
if not ada_satuan:
    continue
gabung = " ".join(potongan)
gabung = re.sub(r"\(\s+", "(", gabung)
gabung = re.sub(r"\s+\)", ")", gabung)
hasil = rapikan_teks(gabung)
if hasil:
    return hasil
return None

```

```

In [9]: # ===== TAHAP 2 - FUNGSI UTAMA: baca, petakan, ekstrak =====
#   baca_dokumen(lintasan)                -> baris, baris_low, jeni
#   petakan_bagian(baris, baris_low, jenis) -> batas tiap bagian + te
#   ekstrak_identitas(baris, jenis, akhir_id) -> nomor putusan + 3 terd
#   ekstrak_amar(baris, bagian, jenis)     -> 3 tuntutan + 2 putusan
#   ekstrak_penutup(penutup, berlaku)     -> tanggal, hakim, panite

```

```

def baca_dokumen(lintasan):
    """Baca .txt -> (baris asli, baris huruf kecil, jenis dokumen dari na
    try:
        teks = lintasan.read_text(encoding="utf-8", errors="replace")
    except Exception:
        teks = lintasan.read_text(encoding="latin-1", errors="replace")
    baris = teks.splitlines()
    baris_low = [x.lower() for x in baris]

    inti = Path(lintasan.name).stem
    if inti.startswith("T-"):
        inti = inti[2:]
    bagian_nama = inti.split("_", 2)
    token = bagian_nama[1] if len(bagian_nama) > 1 else ""
    return baris, baris_low, PETA_JENIS.get(token, "lainnya")

def petakan_bagian(baris, baris_low, jenis):
    """Tentukan batas tiap bagian dokumen.

    Return dict:
        identitas : indeks akhir blok identitas (hanya pidana)
    """

```

```

tuntutan : (awal, akhir) mulai pembacaan tuntutan s.d. pembelaan/d
putusan : (awal, akhir) amar dari MENGADILI terakhir s.d. penutup
penutup : teks kalimat 'Demikian ...' yang sudah dibersihkan
"""
bagian = {"identitas": None, "tuntutan": (None, None), "putusan": (No

# --- penutup: kalimat 'Demikian ...' terakhir ---
mulai = None
for i, x in enumerate(baris):
    if POLA_PENUTUP.search(x):
        mulai = i
if mulai is None:
    mulai = max(0, len(baris) - 80)
awal_p, akhir_p = mulai, min(len(baris), mulai + 45)

if jenis == "pidana":
    # --- identitas: di awal, sebelum status penahanan/pendampingan -
    bagian["identitas"] = min(len(baris), 100)
    for i, x in enumerate(baris[:200]):
        if POLA_BATAS_IDENTITAS.search(x):
            bagian["identitas"] = i
            break

    # --- tuntutan: dari pembacaan tuntutan sampai sebelum pembelaan/
    for i, x in enumerate(baris_low):
        if POLA_AWAL_TUNTUTAN.search(x):
            sekitar = " ".join(baris_low[max(0, i - 2):i + 8])
            if "penuntut umum" not in sekitar and "jaksa" not in seki
                continue
            akhir_t = min(len(baris), i + 400)
            for j in range(i + 1, min(len(baris), i + 400)):
                if (POLA_AKHIR_TUNTUTAN.search(baris[j])
                    or POLA_MENGADILI.match(baris[j])
                    or POLA_PENUTUP.search(baris[j])
                    or re.match(r"^s*Menimbang", baris[j])):
                    akhir_t = j
                    break
            bagian["tuntutan"] = (i, akhir_t)
            break

    # --- putusan: MENGADILI terakhir sebelum penutup (termasuk huruf
    penanda = [i for i, x in enumerate(baris) if POLA_MENGADILI.match
    if penanda:
        kandidat = [i for i in penanda if awal_p is None or i < awal_
        awal_u = kandidat[-1] if kandidat else penanda[-1]
        akhir_u = awal_p if awal_p is not None and awal_p > awal_u el
        bagian["putusan"] = (awal_u, akhir_u)

# --- teks penutup: gabung, buang footer, rapatkan titik gelar ---
teks = " ".join(buang_baris_sampah(baris[awal_p:akhir_p]))
teks = re.sub(r"\s+\.", ".", teks) # 'M.Hum .' -> 'M.Hum.'
teks = re.sub(r"\b([A-Z])\s+(?=[A-Z]\b)", r"\1", teks) # 'S H' -> 'S
teks = re.sub(r",\.(?=\s|$)", ",", teks) # 'MH,.' -> 'MH,'
teks = re.sub(r"\.(?=[Hakim|Panitera|Penuntut|Jaksa)", ". ", teks) #
teks = re.sub(r"([A-Za-z])-([a-z])", r"\1\2", teks) # 'tang-gal' ->
teks = re.sub(r"\bNomor\s*:\s*", "", teks) # buang label 'Nomor :' y
bagian["penutup"] = teks
return bagian

```

```

def ekstrak_identitas(baris, jenis, akhir_identitas):
    """Ambil nomor putusan (30 baris pertama) dan nama terdakwa 1-3 (hany
    # --- nomor putusan: prioritas baris berlabel 'Nomor', lalu baris man
    cocok = None
    for x in baris[:30]:
        if POLA_BARIS_NOMOR.search(x):
            kanan = x.split(":", 1)[1] if ":" in x else x
            cocok = POLA_NOMOR_PUTUSAN.search(kanan)
            if cocok:
                break
    if not cocok:
        for x in baris[:30]:
            cocok = POLA_NOMOR_PUTUSAN.search(x)
            if cocok:
                break

    nomor_putusan = None
    if cocok:
        angka = cocok.group(1).strip()
        if set(angka) != {"-"}: # nomor tersensor semua '-----' dianggap
            jenis_perkara = re.sub(r"\s*/\s*", "/", cocok.group(2).strip()
            tahun = cocok.group(3).strip()
            pengadilan = cocok.group(4)
            if pengadilan:
                pengadilan = re.sub(r"\s+", " ", pengadilan).rstrip(".")
                nomor_putusan = f"{angka}/{jenis_perkara}/{tahun}/PN {pen
            else:
                nomor_putusan = f"{angka}/{jenis_perkara}/{tahun}"

    # --- nama terdakwa (maksimal 3) ---
    nama = []
    if jenis == "pidana":
        for i, x in enumerate(baris[:akhir_identitas]):
            if POLA_LABEL_NAMA.search(x):
                mentah = POLA_LABEL_NAMA.split(baris[i], maxsplit=1)[-1]
                calon = [mentah]
                if ";" not in mentah: # nama bisa tersambung ke baris-ba
                    for j in range(i + 1, min(akhir_identitas, i + 5)):
                        berikut = baris[j]
                        if not berikut.strip():
                            break
                        if POLA_LABEL_NAMA.search(berikut) or POLA_LABEL_
                            break
                        calon.append(berikut)
                        if ";" in berikut:
                            break
                gabung = " ".join(calon)
                bersih = None
                if gabung: # ambil nama sebelum ';' dan buang keterangan
                    depan = re.split(r";", gabung, maxsplit=1)[0]
                    depan = re.split(r",\s*(?:lahir|bertempat|selanjutnya
                    bersih = rapikan_teks(depan)
                    if bersih and len(bersih) > 3 and bersih not in nama:
                        nama.append(bersih)
                if len(nama) >= 3:
                    break
    nama = (nama + [None, None, None])[:3]

    return {"nomor_putusan": nomor_putusan, "nama_terdakwa_1": nama[0],
            "nama_terdakwa_2": nama[1], "nama_terdakwa_3": nama[2]}

```

```

def ekstrak_amar(baris, bagian, jenis):
    """Ambil tuntutan (perbuatan, pasal KUHP, lama hukuman) dan putusan (
    Tuntutan/putusan: amar nomor 1 memuat perbuatan, amar nomor 2 memuat
    hasil = {"tuntutan_pidana": None, "tuntutan_kuhp": None, "tuntutan_hu
            "putusan_pidana": None, "putusan_hukuman": None}
    if jenis != "pidana":
        return hasil

    awal, akhir = bagian["tuntutan"]
    if awal is not None:
        potongan = baris[awal:akhir]
        item1 = ambil_item_amar(potongan, "1", "menyatakan")
        if item1:
            hasil["tuntutan_pidana"] = ambil_perbuatan(item1)
            pasal = re.search(r"(?i)pasal\s+\d+.{0,200}?\s+KUH\s*Pidana|p
            hasil["tuntutan_kuhp"] = rapikan_teks(pasal.group(0)) if pasa
            item2 = ambil_item_amar(potongan, "2", "menjatuhkan")
            if item2:
                hasil["tuntutan_hukuman"] = ambil_lama_pidana(item2)

    awal, akhir = bagian["putusan"]
    if awal is not None:
        potongan = baris[awal:akhir]
        item1 = ambil_item_amar(potongan, "1", "menyatakan")
        if item1:
            hasil["putusan_pidana"] = ambil_perbuatan(item1)
            item2 = ambil_item_amar(potongan, "2", "menjatuhkan")
            if item2:
                hasil["putusan_hukuman"] = ambil_lama_pidana(item2)
    return hasil

def ekstrak_penutup(penutup, berlaku):
    """Ambil tanggal putusan, hakim ketua/anggota, panitera, penuntut umu

    def terdekat(pola):
        """Pilih cocok dengan rentang terpendek (nama paling dekat dengan
        semua = list(pola.finditer(penutup))
        return min(semua, key=lambda m: m.end() - m.start()) if semua else

    # --- tanggal putusan ---
    tanggal = None
    cocok = POLA_TANGGAL.search(penutup)
    if cocok:
        bulan = PETA_BULAN.get(cocok.group(3).lower(), cocok.group(3))
        tanggal = f"{int(cocok.group(2))} {bulan} {cocok.group(4)}"

    # --- panel hakim: pola baku, ad-hoc, lalu tanpa label anggota ---
    panel = (POLA_PANEL_HAKIM.search(penutup) or POLA_PANEL_HAKIM_ADHOC.s
            or POLA_PANEL_TANPA_LABEL.search(penutup))

    ketua = None
    anggota = []
    if panel:
        ketua = rapikan_nama(panel.group("ketua"))
        for nama in POLA_NAMA_BERGELAR.findall(panel.group("anggota")):
            bersih = rapikan_nama(nama)
            if bersih and len(bersih) > 3 and bersih not in anggota:

```

```

        anggota.append(bersih)
    else: # cadangan: 'oleh [kami] NAMA ... Hakim' tanpa label ketua/ang
        for cocok in re.finditer(r"(?:\boleh)(?:\s+kami)?\s*[,:;]?s*("
            sesudah = penutup[cocok.end():cocok.end() + 250]
            if re.search(r"(?:\bHakim\b(?:\s+(?:Anggota|Ketua|Majelis|-|
                ketua = rapikan_nama(cocok.group(1))
                break

# --- panitera pengganti (cadangan: aposisi ', NAMA, Panitera Penggan
cocok = terdekat(POLA_PANITERA) or terdekat(POLA_PANITERA_APOSISI)
panitera = rapikan_nama(cocok.group("nama")) if cocok else None

# --- penuntut umum (hanya pidana; cadangan: nama tanpa gelar) ---
penuntut_umum = None
if "penuntut_umum" in berlaku:
    cocok = terdekat(POLA_JPU)
    if cocok:
        penuntut_umum = rapikan_teks(cocok.group("nama"))
    else:
        cocok = terdekat(POLA_JPU_POLLOS)
        if cocok:
            nama = rapikan_nama(cocok.group("nama"))
            if nama and not re.search(r"(?:\b(terdakwa|pemohon|advok
                penuntut_umum = nama

return {"tanggal_putusan": tanggal, "hakim_ketua": ketua,
        "hakim_anggota_1": anggota[0] if len(anggota) >= 1 else None,
        "hakim_anggota_2": anggota[1] if len(anggota) >= 2 else None,
        "panitera": panitera, "penuntut_umum": penuntut_umum}

```

```

In [10]: # ===== TAHAP 2 - FUNGSI UTAMA: orkestrator & pengendali =====
# ekstrak(lintasan_txt)          -> 15 entitas + keterangan satu file
# tulis_keluaran_txt(...)        -> tulis 0-*.txt
# demo_satu_file()               -> demo 1 file + jejak aturan
# proses_batch()                 -> semua file -> 0-*.txt + entitas_258.cs
# tampilkan_ringkasan()          -> 5 data teratas + rekap + cakupan tiap

```

```

def ekstrak(lintasan_txt: Path):
    """Ekstrak 15 entitas dan keterangan dari satu file."""
    try:
        baris, baris_low, jenis = baca_dokumen(lintasan_txt)
        berlaku = himpunan_berlaku(jenis)
        bagian = petakan_bagian(baris, baris_low, jenis)

        # kumpulkan semua nilai yang ditemukan (None = tidak ditemukan)
        ditemukan = {}
        ditemukan.update(ekstrak_identitas(baris, jenis, bagian["identita
        ditemukan.update(ekstrak_amar(baris, bagian, jenis))
        ditemukan.update(ekstrak_penutup(bagian["penutup"], berlaku))

        # isi hasil; alasan kosong dicatat per entitas
        hasil = {kunci: TANDA_KOSONG for kunci in KOLOM_ENTITAS}
        alasan = {}
        for kunci in KOLOM_ENTITAS:
            if kunci not in berlaku:
                alasan[kunci] = f"tidak berlaku untuk dokumen {jenis}"
            elif ditemukan.get(kunci):
                hasil[kunci] = ditemukan[kunci]
            else:

```

```

        alasan[kunci] = PESAN_KOSONG[kunci]

    terisi = sum(1 for kunci in berlaku if hasil.get(kunci) not in (T
if terisi == len(berlaku):
    status = "lengkap"
elif terisi == 0:
    status = "kosong"
else:
    status = "sebagian"
hilang = [kunci for kunci in KOLOM_ENTITAS if hasil.get(kunci) ==
catatan = "; ".join(f"{kunci}: {alasan.get(kunci, 'tidak ditemukan')}"
return {**hasil, "_ok": True, "_error": None, "file_txt": lintasa
        "jenis_dokumen": jenis, "entitas_berlaku": len(berlaku),
        "total_entitas_terisi": sum(1 for kunci in KOLOM_ENTITAS
        "status_lengkap": status,
        "catatan_kosong": catatan or "semua entitas yang berlaku
except Exception as salah:
    kosong = {kunci: TANDA_KOSONG for kunci in KOLOM_ENTITAS}
    return {**kosong, "_ok": False, "_error": str(salah), "file_txt":
        "jenis_dokumen": "tidak-diketahui", "entitas_berlaku": 0,
        "total_entitas_terisi": 0, "status_lengkap": "gagal",
        "catatan_kosong": f"ERROR: {salah}"}

def tulis_keluaran_txt(lintasan, hasil):
    """Tulis satu entitas per baris memakai label yang mudah dibaca."""
    with open(lintasan, "w", encoding="utf-8") as berkas:
        berkas.write("=== ENTITAS TEREKSTRAKSI ===\n")
        berkas.write(f"File Sumber : {hasil['file_txt']}\n")
        berkas.write(f"Jenis Dokumen : {hasil['jenis_dokumen']}\n")
        berkas.write(f>Status : {hasil['status_lengkap']} ({hasil[
        berkas.write("-" * 60 + "\n")
        for kunci in KOLOM_ENTITAS:
            berkas.write(f"{LABEL_CETAK[kunci]:17s} : {hasil[kunci]}\n")
        berkas.write("-" * 60 + "\n")
        berkas.write("Catatan Kosong:\n")
        berkas.write(hasil["catatan_kosong"] + "\n")

def demo_satu_file():
    """Demo 1 file: cetak proses scraping, hasil tiap entitas beserta atu
    OUTPUT_CLEAN.mkdir(exist_ok=True)
    contoh = INPUT_TXT / CONTOH_DEMO
    if not contoh.exists():
        kandidat = sorted([x for x in INPUT_TXT.glob("T-*.txt") if "_Pid.
        contoh = kandidat[0]
    print(">> Proses scraping entitas")
    print(f">> Membaca: {contoh.name}")
    hasil = ekstrak(contoh)
    print(f">> Jenis dokumen: {hasil['jenis_dokumen']} | Terisi: {hasil[
    print(">> Hasil tiap entitas dan aturan yang dipakai:")
    for kunci in KOLOM_ENTITAS:
        tanda = "✓" if hasil[kunci] != TANDA_KOSONG else "x"
        print(f" {tanda} {LABEL_CETAK[kunci]:17s} = {hasil[kunci]}")
        print(f"      aturan: {JEJAK_ATURAN[kunci]}")
    print(">> Alasan nilai kosong:")
    print(f"      {hasil['catatan_kosong']}")
    tulis_keluaran_txt(OUTPUT_CLEAN / f"O-{contoh.name}", hasil)
    print(f">> Ditulis: OUTPUT_CLEAN/O-{contoh.name}")
    return hasil

```

```

def proses_batch():
    """Proses semua T-*.txt di CLEAN_TXT/ menjadi 0-*.txt + satu CSV rang
    OUTPUT_CLEAN.mkdir(exist_ok=True)
    semua = sorted(INPUT_TXT.glob("T-*.txt"))
    print(f">> Memproses {len(semua)} file dari CLEAN_TXT/ ...")
    baris_csv = []
    berhasil = 0
    gagal = 0
    for berkas in semua:
        hasil = ekstrak(berkas)
        if hasil.get("_ok"):
            berhasil += 1
        else:
            gagal += 1
        tulis_keluaran_txt(OUTPUT_CLEAN / f"0-{berkas.name}", hasil)
        baris_csv.append([str(hasil.get(kunci, TANDA_KOSONG) if hasil.get
            for kunci in KOLOM_CSV)])
    jalur_csv = OUTPUT_CLEAN / "entitas_258.csv"
    with open(jalur_csv, "w", newline="", encoding="utf-8") as csv_file:
        tulis = csv.writer(csv_file)
        tulis.writerow(KOLOM_CSV)
        tulis.writerows(baris_csv)
    print(">> Rekap batch:")
    print(f" Total file : {len(semua)}")
    print(f" Berhasil : {berhasil}")
    print(f" Gagal : {gagal}")
    print(f">> CSV : {jalur_csv}")
    print(f">> TXT : {OUTPUT_CLEAN} (0-*.txt)")
    return jalur_csv

def tampilkan_ringkasan():
    """Tampilkan 5 data teratas, rekap status/jenis, dan cakupan tiap ent
    jalur_csv = OUTPUT_CLEAN / "entitas_258.csv"
    if not jalur_csv.exists():
        print("CSV belum ada. Jalankan cell batch terlebih dahulu.")
        return
    with open(jalur_csv, encoding="utf-8") as csv_file:
        semua_baris = list(csv.DictReader(csv_file))

    print(f">> Menampilkan {BATAS_PREVIEW} data teratas dari {jalur_csv}")
    print("=" * 100)
    for nomor, baris in enumerate(semua_baris[:BATAS_PREVIEW], 1):
        print(f"\n[{nomor}] {baris['file_txt']} | {baris['jenis_dokumen']}")
        print("-" * 100)
        for kunci in KOLOM_ENTITAS:
            print(f" {LABEL_CETAK[kunci]:17s} : {baris[kunci]}")
        print(f" Catatan : {baris['catatan_kosong']}")
    print("\n" + "=" * 100)
    print(">> Rekap status:", dict(Counter(x["status_lengkap"] for x in s
    print(">> Rekap jenis :", dict(Counter(x["jenis_dokumen"] for x in se

    print("\n>> Cakupan entitas (terisi dibagi jumlah berlaku)")
    print("-" * 60)
    for kunci in KOLOM_ENTITAS:
        berlaku = sum(1 for x in semua_baris if kunci in himpunan_berlaku
        isi = sum(1 for x in semua_baris if x.get(kunci) not in (TANDA_KO
        print(f" {kunci:20s} : {isi:3d} / {berlaku:3d}")

```

```
print("-" * 60)
```

Jalankan tahap 2

```
In [11]: # 1) Demo 1 file + jejak aturan
hasil_demo = demo_satu_file()
```

```
>> Proses scraping entitas
>> Membaca: T-1016_Pid.B_2026_PN Sby.txt
>> Jenis dokumen: pidana | Terisi: 12/15 | Status: sebagian
>> Hasil tiap entitas dan aturan yang dipakai:
  ✓ Nomor Putusan      = 1016/Pid.B/2026/PN Sby
    aturan: baris judul 'Nomor :' + POLA_NOMOR
  ✓ Nama Terdakwa 1    = Vicky Dubes Borty Bin M Irfan Wijaya
    aturan: label Nama di blok identitas pidana
  x Nama Terdakwa 2    = -
    aturan: label Nama kedua di blok identitas pidana
  x Nama Terdakwa 3    = -
    aturan: label Nama ketiga di blok identitas pidana
  ✓ Tuntutan Pidana    = yang secara melawan hukum memiliki suatu barang ya
ng sebagian atau seluruhnya milik orang lain, yang ada dalam kekuasaannya
bukan
    aturan: amar 1 Tuntutan + frasa sesudah 'bersalah melakukan'
  x Tuntutan KUHP      = -
    aturan: amar 1 Tuntutan + pola 'Pasal ... KUHP'
  ✓ Tuntutan Hukuman   = 1 (satu) tahun 3 (tiga) bulan
    aturan: amar 2 Tuntutan + durasi sesudah 'selama'
  ✓ Putusan Pidana     = Penggelepan
    aturan: amar 1 MENGADILI + frasa sesudah 'bersalah melakukan'
  ✓ Putusan Hukuman    = 1 (satu) tahun dan 1 (satu) bulan
    aturan: amar 2 MENGADILI + durasi sesudah 'selama'
  ✓ Tanggal Putusan    = 2 September 2026
    aturan: kalimat 'Demikian ...' + pola 'pada hari, tanggal'
  ✓ Hakim Ketua       = Edi Saputra Pelawi, S.H., M.H.
    aturan: nama sebelum 'sebagai/selaku Hakim Ketua'
  ✓ Hakim Anggota 1   = Sagung Bunga Mayasaputri Antara, S.H.
    aturan: nama pertama sebelum 'masing-masing ... Anggota'
  ✓ Hakim Anggota 2   = S. Pujiono, S.H., M.Hum.
    aturan: nama kedua sebelum 'masing-masing ... Anggota'
  ✓ Panitera          = Sigit Nugroho, SH
    aturan: nama sesudah 'dibantu oleh' sebelum 'Panitera Pengganti'
  ✓ Penuntut Umum     = Wicaksono Subekti R.,S.H.
    aturan: nama sesudah 'dihadiri oleh' sebelum 'Penuntut Umum'
>> Alasan nilai kosong:
    nama_terdakwa_2: dokumen ini tidak mempunyai terdakwa kedua/ketiga; na
ma_terdakwa_3: dokumen ini tidak mempunyai terdakwa kedua/ketiga; tuntutan
_kuhp: amar Tuntutan nomor 1 tidak memuat Pasal KUHP
>> Ditulis: OUTPUT_CLEAN/0-T-1016_Pid.B_2026_PN Sby.txt
```

```
In [12]: # 2) Batch semua file -> 0-*.txt + entitas_258.csv
jalur_csv = proses_batch()
```

```
>> Memproses 258 file dari CLEAN_TXT/ ...
>> Rekap batch:
  Total file : 258
  Berhasil   : 258
  Gagal      : 0
>> CSV       : OUTPUT_CLEAN/entitas_258.csv
>> TXT       : OUTPUT_CLEAN (0-*.txt)
```

```
In [13]: # 3) 5 data teratas, rekap status/jenis, dan cakupan tiap entitas  
         tampilkan_ringkasan()
```

```
>> Menampilkan 5 data teratas dari OUTPUT_CLEAN/entitas_258.csv
```

```
[1] T-1002_Pid.Sus-LH_2026_PN Sby.txt | pidana | 12/15 | sebagian
```

```
-----  
-----  
Nomor Putusan      : 1002/Pid.Sus-LH/2026/PN Sby  
Nama Terdakwa 1    : HENDRIK SETIAWAN BIN (alm) ABDUL HALIM  
Nama Terdakwa 2    : -  
Nama Terdakwa 3    : -  
Tuntutan Pidana    : menyalagunakan Pengangkutan dan/atau Niaga Bahan Bak  
ar Minyak, Bahan Bakar Gas, dan/atau liquefied petroleum gas yang disbusid  
i dan/atau penyediaan dan pendistribusiannya diberikan penugasan pemerinta  
h  
Tuntutan KUHP      : -  
Tuntutan Hukuman   : 1 (satu) Tahun dan 6 (enam) bulan  
Putusan Pidana     : menyalahgunakan niaga bahan bakar minyak yang disubs  
idi dan atau penyediaan dan pendistribusiannya diberikan penugasan pemerin  
tah  
Putusan Hukuman    : 1 (satu) tahun dan 2 (dua) bulan  
Tanggal Putusan    : 31 Agustus 2026  
Hakim Ketua       : Alex Adam Faisal, S.H., M.H.  
Hakim Anggota 1    : Dr. Nur Kholis, S.H., M.H.  
Hakim Anggota 2    : Antyo Harri Susetyo, S.H.  
Panitera          : Alarico De Jesus, S.H.  
Penuntut Umum     : Reiyan Novandana Syanur Putra, S.H.  
Catatan           : nama_terdakwa_2: dokumen ini tidak mempunyai terdakwa kedu  
a/ketiga; nama_terdakwa_3: dokumen ini tidak mempunyai terdakwa kedua/keti  
ga; tuntutan_kuhp: amar Tuntutan nomor 1 tidak memuat Pasal KUHP
```

```
[2] T-1013_Pid.B_2026_PN Sby.txt | pidana | 12/15 | sebagian
```

```
-----  
-----  
Nomor Putusan      : 1013/Pid.B/2026/PN Sby  
Nama Terdakwa 1    : ATMAWI Bin MARSUI (alm)  
Nama Terdakwa 2    : -  
Nama Terdakwa 3    : -  
Tuntutan Pidana    : Penadahan  
Tuntutan KUHP      : -  
Tuntutan Hukuman   : 8 (delapan) bulan  
Putusan Pidana     : penadahan  
Putusan Hukuman    : 5 (lima) bulan  
Tanggal Putusan    : 6 Agustus 2026  
Hakim Ketua       : Sarlota Marselina Suek, S.H.  
Hakim Anggota 1    : Gede Putra Astawa, S.H., M.H.  
Hakim Anggota 2    : Agus Cakra Nugraha, S.H., M.H.  
Panitera          : Alarico De Jesus, S.H.  
Penuntut Umum     : Moch. Mosleh Rahman, S.H.  
Catatan           : nama_terdakwa_2: dokumen ini tidak mempunyai terdakwa kedu  
a/ketiga; nama_terdakwa_3: dokumen ini tidak mempunyai terdakwa kedua/keti  
ga; tuntutan_kuhp: amar Tuntutan nomor 1 tidak memuat Pasal KUHP
```

```
[3] T-1016_Pid.B_2026_PN Sby.txt | pidana | 12/15 | sebagian
```

```
-----  
-----  
Nomor Putusan      : 1016/Pid.B/2026/PN Sby  
Nama Terdakwa 1    : Vicky Dubes Borty Bin M Irfan Wijaya  
Nama Terdakwa 2    : -  
Nama Terdakwa 3    : -
```

Tuntutan Pidana : yang secara melawan hukum memiliki suatu barang yang sebagian atau seluruhnya milik orang lain, yang ada dalam kekuasaannya bukan

Tuntutan KUHP : -
Tuntutan Hukuman : 1 (satu) tahun 3 (tiga) bulan
Putusan Pidana : Penggelepan
Putusan Hukuman : 1 (satu) tahun dan 1 (satu) bulan
Tanggal Putusan : 2 September 2026
Hakim Ketua : Edi Saputra Pelawi, S.H., M.H.
Hakim Anggota 1 : Sagung Bunga Mayasaputri Antara, S.H.
Hakim Anggota 2 : S. Pujiono, S.H., M.Hum.
Panitera : Sigit Nugroho, SH
Penuntut Umum : Wicaksono Subekti R., S.H.

Catatan : nama_terdakwa_2: dokumen ini tidak mempunyai terdakwa kedua/ketiga; nama_terdakwa_3: dokumen ini tidak mempunyai terdakwa kedua/ketiga; tuntutan_kuhp: amar Tuntutan nomor 1 tidak memuat Pasal KUHP

[4] T-1021_Pid.Sus_2026_PN Sby.txt | pidana | 12/15 | sebagian

Nomor Putusan : 1021/Pid.Sus/2026/PN Sby
Nama Terdakwa 1 : Mochammad Maulid Irhas Bin Namin
Nama Terdakwa 2 : -
Nama Terdakwa 3 : -
Tuntutan Pidana : yang tanpa hak atau melawan hukum menawarkan untuk dijual, menjual, membeli, menerima, menjadi perantara dalam jual beli, Tuntutan KUHP : -
Tuntutan Hukuman : 3 (tiga) Tahun
Putusan Pidana : Tanpa hak atau melawan hukum menawarkan untuk dijual, menjual, membeli, menerima, menjadi perantara dalam jual beli, menukar atau menyerahkan Narkotika Golongan I
Putusan Hukuman : 3 (tiga) tahun
Tanggal Putusan : 3 September 2026
Hakim Ketua : Teguh Santoso, S.H.
Hakim Anggota 1 : Betsji Siske Manoe, S.H., M.H.
Hakim Anggota 2 : Muhammad Sukanto, S.H., M.H.
Panitera : Iyut Pandu Risdianto, S.H.
Penuntut Umum : Wicaksono Subekti R
Catatan : nama_terdakwa_2: dokumen ini tidak mempunyai terdakwa kedua/ketiga; nama_terdakwa_3: dokumen ini tidak mempunyai terdakwa kedua/ketiga; tuntutan_kuhp: amar Tuntutan nomor 1 tidak memuat Pasal KUHP

[5] T-1050_Pid.Sus_2026_PN Sby.txt | pidana | 12/15 | sebagian

Nomor Putusan : 1050/Pid.Sus/2026/PN Sby
Nama Terdakwa 1 : IDAM MAULANA BIN NIWI
Nama Terdakwa 2 : -
Nama Terdakwa 3 : -
Tuntutan Pidana : Narkotika “ tanpa hak atau melawan hukum menawarkan untuk dijual, menjual, membeli, menjadi perantara dalam jual beli, menukar, menyerahkan, atau menerima Narkotika Golongan I yang dalam bentuk tanaman beratnya melebihi 1 (satu) kilogram atau melebihi 5 (lima) batang pohon atau dalam bentuk bukan tanaman beratnya 5 (lima) gram”
Tuntutan KUHP : -
Tuntutan Hukuman : 9 (Sembilan) tahun
Putusan Pidana : tanpa hak atau melawan hukum menawarkan untuk dijual, menjual, membeli, menerima, menjadi perantara dalam jual beli, menukar, atau menyerahkan Narkotika Golongan I dalam bentuk bukan tanaman yang beratnya melebihi 5 (lima) gram

Putusan Hukuman : 9 (Sembilan) tahun
 Tanggal Putusan : 10 September 2026
 Hakim Ketua : Aloysius Priharnoto Bayuaji, S.H., M.H.
 Hakim Anggota 1 : Alex Adam Faisal, S.H, M.H.
 Hakim Anggota 2 : Shaktiana, S.H., M.H.
 Panitera : Rizky Wirianto, SH., MH
 Penuntut Umum : Ida Bagus Made Adi Suputra, S.H.
 Catatan : nama_terdakwa_2: dokumen ini tidak mempunyai terdakwa kedua/ketiga; nama_terdakwa_3: dokumen ini tidak mempunyai terdakwa kedua/ketiga; tuntutan_kuhp: amar Tuntutan nomor 1 tidak memuat Pasal KUHP

```
=====
```

```
>> Rekap status: {'sebagian': 201, 'lengkap': 57}
>> Rekap jenis : {'pidana': 99, 'gugatan': 37, 'hki-merek': 2, 'permohonan': 97, 'pailit-pkpu': 8, 'praperadilan': 1, 'bantahan': 4, 'gugatan-sederhana': 3, 'phi': 6, 'renvoi': 1}
```

```
>> Cakupan entitas (terisi dibagi jumlah berlaku)
```

```
-----
nomor_putusan      : 257 / 258
nama_terdakwa_1    : 99 / 99
nama_terdakwa_2    : 14 / 99
nama_terdakwa_3    : 1 / 99
tuntutan_pidana    : 88 / 99
tuntutan_kuhp      : 26 / 99
tuntutan_hukuman   : 88 / 99
putusan_pidana     : 98 / 99
putusan_hukuman    : 99 / 99
tanggal_putusan    : 258 / 258
hakim_ketua        : 256 / 258
hakim_anggota_1    : 155 / 258
hakim_anggota_2    : 155 / 258
panitera           : 258 / 258
penuntut_umum      : 98 / 99
-----
```

```
In [17]: # ===== Gabungkan 5 hasil 0-*.txt menjadi satu PDF (IE-RuleBased-Hasil-<n
import textwrap
from pathlib import Path
from reportlab.lib.pagesizes import A4
from reportlab.lib.styles import getSampleStyleSheet
from reportlab.lib.units import cm
from reportlab.platypus import SimpleDocTemplate, Paragraph, Preformatted

NIM = "230411100145" # <-- ganti dengan NIM Anda
FILE_PILIHAN = [ # <-- ganti dengan 5 file pilihan
    "0-T-1016_Pid.B_2026_PN Sby.txt",
    "0-T-191_Pid.B_2018_PN SBY.txt",
    "0-T-1184_Pid.Sus_2026_PN Sby.txt",
    "0-T-55_Pid.Sus-TPK_2026_PN Sby.txt",
    "0-T-1057_Pid.B_2026_PN Sby.txt",
]
LEBAR_BARIS = 88 # karakter per baris (Courier 8 pt

gaya = getSampleStyleSheet()
gaya_kode = gaya["Code"].clone("kode", fontName="Courier", fontSize=8, le
isi = []
for nomor, nama in enumerate(FILE_PILIHAN, 1):
    teks = (Path("OUTPUT_CLEAN") / nama).read_text(encoding="utf-8")
```

```
baris = []
for b in teks.splitlines():
    baris += textwrap.wrap(b, LEBAR_BARIS, subsequent_indent="    ")
isi.append(Paragraph(f"Hasil {nomor}: {nama}", gaya["Heading3"]))
isi.append(Spacer(1, 0.3 * cm))
isi.append(Preformatted("\n".join(baris), gaya_kode))
if nomor < len(FILE_PILIHAN):
    isi.append(PageBreak())

SimpleDocTemplate(f"IE-RuleBased-Hasil-{NIM}.pdf", pagesize=A4,
                  leftMargin=2*cm, rightMargin=2*cm, topMargin=2*cm, bottomMargin=2*cm)
print(f"Selesai: IE-RuleBased-Hasil-{NIM}.pdf ({len(FILE_PILIHAN)} hasil)
```

Selesai: IE-RuleBased-Hasil-230411100145.pdf (5 hasil)